
Previsão da gravidade de acidentes em rodovias federais de Santa Catarina com Regressão Logística e KNN

Bruno Pagani Rampinelli
João Henrique Camilo Fogaça
Vinícius dos Santos Nascimento

Projeto Machine Learning
Engenharia de Computação | UNISATC

Contexto

- As rodovias federais são fiscalizadas pela **Polícia Rodoviária Federal (PRF)**.
- Em 2025, as rodovias federais do país registraram, de acordo com a CNT:

72.476
acidentes

6.040
mortes

- Só a BR-101 concentra **17,9%** dos acidentes do país.
- A fiscalização, hoje, usa pontos críticos e operações em datas de maior movimento.

Estado da arte (1/6)

Revista Eletrônica de Iniciação Científica em Computação, 2025, 23:1

ISSN: 3085-8461 • doi: 10.5753/reic.2025.6274

© This work is licensed under a Creative Commons Attribution 4.0 International License.

ARTIGO DE PESQUISA/RESEARCH PAPER

Técnicas de Aprendizado de Máquina para Predição de Gravidade de Acidentes em Rodovias do Estado do Rio de Janeiro

Machine Learning Techniques for Predicting the Severity of Accidents on Highways in the State of Rio de Janeiro

Evandro V. Mafort   [Centro Federal de Educação Tecnológica Celso Suckow da Fonseca | evandro.mafort@aluno.cefet-rj.br]

Marco A. A. Kappel   [Centro Federal de Educação Tecnológica Celso Suckow da Fonseca | marco.kappel@cefet-rj.br]

 Centro Federal de Educação Celso Suckow da Fonseca, Av. Gov. Roberto Silveira, 1900, Jd. Ouro Preto, Nova Friburgo, RJ, 28635-000, Brasil.

Resumo. Devido à sua dependência do transporte rodoviário, a segurança viária é um desafio significativo no Brasil. O estado do Rio de Janeiro apresenta padrões recorrentes de acidentes graves, demandando a identificação de seus principais fatores de risco. Este estudo aplicou técnicas de aprendizado de máquina para desenvolver um modelo preditivo para a gravidade de acidentes ocorridos nas rodovias federais do estado entre 2020 e 2023, utilizando dados da Polícia Rodoviária Federal (PRF). Foram comparados sete algoritmos de classificação supervisionada, com hiperparâmetros otimizados e avaliação por validação cruzada. O modelo de Regressão Logística apresentou o desempenho mais robusto, alcançando 73,85% de acurácia. A análise de interpretabilidade com a ferramenta LIME indicou que o tipo de acidente, a fase do dia, as condições meteorológicas, a localização geográfica e a densidade de acidentes por quilômetro foram os preditores mais influentes. Os resultados podem subsidiar a formulação de políticas públicas de prevenção mais eficazes.

Abstract. Due to its reliance on road transportation, road safety is a significant challenge in Brazil. The state of Rio de Janeiro exhibits recurring patterns of severe accidents, demanding the identification of its main risk factors. This study applied machine learning techniques to develop a predictive model for accident severity on the state's federal highways

Mafort e Kappel

- Dados da PRF (RJ);
- Aplicação de sete algoritmos;
- Regressão Logística (ROC 0,689);
- Divisão aleatória;
- Trabalho mais próximo;
- E o desbalanceamento?

Estado da arte (2/6)

Rosiane de Freitas
Diego Furtado (Eds.)

LNAI 16181

Intelligent Systems

35th Brazilian Conference, BRACIS 2025
Fortaleza-CE, Brazil, September 29 – October 2, 2025
Proceedings, Part III

Gabardo et al.

- Dados da PRF (região sul);
- Lida com desbalanceamento (que faz modelo promover classe majoritária);
- Random Forest, KNN e rede neural com SMOTE (AUC 0,99).

Estado da arte (3/6)



Scientia Generalis 2675-2999

v. 7, n. 1, p. 1157-1175. 2026.

Artigo Original



APRENDIZADO DE MÁQUINA NA ANÁLISE DE SINISTROS DE TRÂNSITO: Um estudo na zona urbana de Teresina - PI

DOI: 10.22289/sg.V7N1A94

George Isaac Lopes de Sousa ^a, Maria Clara de Oliveira Rodrigues ^a e Amanda Gadelha Ferreira Rosa ^{a*}

^a Universidade Federal do Piauí - UFPI, Teresina, Piauí, Brasil.

Resumo

A segurança viária representa um desafio crescente para a mobilidade urbana, especialmente em cidades brasileiras com elevada incidência de sinistros de trânsito. Este estudo propõe uma análise dos sinistros de trânsito registrados na zona urbana de Teresina - PI, por meio de modelos de Aprendizagem de Máquina para a classificação da natureza destes eventos, baseando-se na localização espacial destes eventos para a criação de um *baseline* para desenvolvimento de estratégias de apoio ao planejamento de políticas públicas. A pesquisa seguiu as etapas do processo *Knowledge Discovery in Databases* (KDD) e utilizou uma base governamental contendo 4.803 registros georreferenciados válidos. Após o pré-processamento dos dados, foram aplicados os algoritmos supervisionados Regressão Logística e Floresta Aleatória para classificação da severidade dos sinistros. Considerando o desbalanceamento das classes, empregou-se a técnica *Synthetic Minority Over-sampling Technique* (SMOTE) durante o treinamento dos modelos. Os resultados mostraram que, antes do balanceamento, os algoritmos apresentaram baixa capacidade de identificar ocorrências fatais, concentrando as previsões nas classes majoritárias. Com a aplicação do SMOTE, houve melhora na detecção das classes minoritárias, especialmente pela Regressão Logística. Entretanto, os indicadores de desempenho permaneceram limitados, sugerindo que as variáveis espaciais utilizadas não explicam, isoladamente, a severidade dos sinistros. Conclui-se que a inclusão de fatores viários, ambientais e comportamentais pode aprimorar a capacidade preditiva dos modelos.

Palavras-chave: Sinistros de Trânsito; Aprendizado de Máquina; KDD; SMOTE; Mobilidade Urbana.

MACHINE LEARNING IN TRAFFIC ACCIDENT ANALYSIS:

A study in the urban area of Teresina

Sousa et al.

- Reforça necessidade de lidar com balanceamento;
- Modelo passou a reconhecer acidentes fatais após aplicação de balanceamento SMOTE.

Estado da arte (4/6)



infrastructures



Article

Handling Imbalanced Data in Road Crash Severity Prediction by Machine Learning Algorithms

Nicholas Fiorentini * and Massimo Losa

Department of Civil and Industrial Engineering (DICI), Engineering School of the University of Pisa, Largo Lucio Lazzarino 1, 56126 Pisa, Italy; losa@ing.unipi.it

* Correspondence: nicholas.fiorentini@phd.unipi.it

Received: 13 June 2020; Accepted: 15 July 2020; Published: 20 July 2020



Abstract: Crash severity is undoubtedly a fundamental aspect of a crash event. Although machine learning algorithms for predicting crash severity have recently gained interest by the academic community, there is a significant trend towards neglecting the fact that crash datasets are acutely imbalanced. Overlooking this fact generally leads to weak classifiers for predicting the minority class (crashes with higher severity). In this paper, in order to handle imbalanced accident datasets and provide a better prediction for the minority class, the random undersampling the majority class (RUMC) technique is used. By employing an imbalanced and a RUMC-based balanced training set, we propose the calibration, validation, and evaluation of four different crash severity predictive models, including random tree, k-nearest neighbor, logistic regression, and random forest. Accuracy, true positive rate (recall), false positive rate, true negative rate, precision, F_1 -score, and the confusion matrix have been calculated to assess the performance. Outcomes show that RUMC-based models provide an enhancement in the reliability of the classifiers for detecting fatal crashes and those causing injury. Indeed, in imbalanced models, the true positive rate for predicting fatal crashes and those causing injury spans from 0% (logistic regression) to 18.3% (k-nearest neighbor), while for the RUMC-based models, it spans from 52.5% (RUMC-based logistic regression) to 57.2% (RUMC-based k-nearest neighbor). Organizations and decision-makers could make use of RUMC and machine learning

Fiorentini e Losa

- Árvore de decisão, KNN, Random Forest e Regressão Logística, com e sem subamostragem;
- Investigar falsos positivos (acidente não-grave tido como grave) e falsos negativos (acidente grave não reconhecido).

Estado da arte (5/6)

35º Congresso de Pesquisa e Ensino em Transporte da ANPET
100% Virtual | 08, 10, 12, 16 e 18 de novembro de 2021



ACIDENTES EM RODOVIAS BRASILEIRAS: UM ESTUDO COM TÉCNICAS DE MACHINE LEARNING PARA CLASSIFICAR A CAUSA DAS OCORRÊNCIAS

Eveline Oliveira Malaquias
Marielce de Cássia Ribeiro Tosta
Gisele de Lorena Diniz Chaves
Departamento de Engenharias e Tecnologia
Universidade Federal do Espírito Santo
Glaydston Mattos Ribeiro
Programa de Engenharia de Transportes – COPPE
Universidade Federal do Rio de Janeiro

RESUMO

Os acidentes de trânsito são um problema mundial que geram consequências sociais, econômicas e de saúde. Para identificar os pontos críticos e propor soluções é necessário investigar as principais causas e elementos associados aos eventos de risco. Isso requer métodos para identificar a causa dos acidentes de trânsito para auxiliar o trabalho dos agentes de segurança no registro das ocorrências e contribuir para uma base de dados confiável. Nesse sentido, este estudo propõe um modelo de classificação de causas de acidentes de trânsito ocorridos em rodovias federais brasileiras. Para isso, utilizou-se modelos de Machine Learning. O modelo projetado com melhor performance foi o algoritmo Floresta Aleatória, capaz de prever a causa dos acidentes com acurácia de 69%. Apesar de não alcançar o valor máximo de desempenho, conclui-se que o modelo foi capaz de aprender o comportamento dos dados e generalizar novas ocorrências, fornecendo uma classificação das causas de acidentes rodoviários no Brasil, assim como principais fatores de riscos. Este resultado pode auxiliar políticas públicas para prevenção destes acidentes.

ABSTRACT

Traffic accidents are a worldwide problem that generate social, economic and health consequences. To identify critical points and propose solutions, it is necessary to investigate the main causes and elements associated with risk events. This requires methods to identify the cause of traffic accidents to assist the security agents in recording occurrences contributing to a reliable database. In this sense, this study proposes a model for classifying the causes

Malaquias et al.

- Classifica causa, não gravidade;
- Random forest + subamostragem;
- 69% de acurácia.

Estado da arte (6/6)

Visualização dos dados abertos da Polícia Rodoviária Federal sobre acidentes nas rodovias brasileiras

Victor G. P. de Mattos, Pedro H. V. Vasconcelos, Yussef Parcianello,
Nádia P. Kozievitch, Rita Berardi

¹Universidade Tecnológica Federal do Paraná (UTFPR)
Avenida Sete de Setembro, 3165
Departamento Acadêmico de Informática – DAINF – Curitiba – Brasil

{victormattos, pedrovasconcelos}@alunos.utfpr.edu.br,
yussef.parcianello@ifsc.edu.br, {nadiap, ritaberardi}@utfpr.edu.br

Abstract. *Traffic accidents are one of the main causes of death in Brazil and, in the last 10 years, more than 1.6 million accidents along with 83 thousand deaths were registered. This paper proposes an open-source prototype for the visualization of open data provided by Polícia Rodoviária Federal (PRF), mapping historically the most dangerous sections of the highways, the most frequent causes of accidents, and helps to identify patterns. The purpose of this paper is to promote the awareness of users, aiming at preventing and reducing the number of accidents on Brazilian highways, which today, in addition to human loss, generate an average loss of R\$10 billion annually.*

Resumo. *Os acidentes de trânsito são uma das principais causas de óbito no Brasil e, somente nos últimos 10 anos, foram registrados mais de 1.6 milhões de acidentes e mais de 83 mil mortes. Este artigo propõe um protótipo de código aberto para a visualização dos dados abertos da Polícia Rodoviária Federal (PRF), mapeando os trechos historicamente mais perigosos nas rodovias, auxiliando na identificação de padrões. O intuito deste artigo é promover a conscientização dos usuários, visando a prevenção e diminuição no número de*

Mattos et al.

- PRF: 2007 a 2018;
- Não é um classificador;
- Serviu como base para a aplicação web deste projeto.

Estado da arte: conclusões

- **Dados:** Utilização dos dados da PRF é viável;
- **Desbalanceamento:** é um problema recorrente que requer tratamento;
- **Interpretação de FP e FN:** podem influenciar na qualidade do modelo escolhido;
- **Algoritmos:** uso de Regressão Logística e KNN;
- **Divisão dos dados:** divisão aleatória é mais comum.

Problema de Machine Learning

Dadas as condições do acidente, qual a chance de ele ter sido fatal?

- **Classificação:** Binária
- **Variável alvo:** Grave (1 se o acidente teve vítima fatal, 0 nos demais casos)
- **Uso:** Analisar acidentes registrados e apontar condições ligadas à letalidade, prevendo se foi ou não fatal

Dados

- Dados abertos da PRF, de 2021 a 2025, filtrados para Santa Catarina.
- 39.849 acidentes e 31 colunas, uma linha por acidente.
- Só 4,2% são fatais: um caso grave para cada 24 não graves.

Classificação	Qtd.	%
Com feridos	31.996	80,29%
Sem vítimas	6.179	15,51%
Com fatais	1.674	4,20%

Dados: método

- Higiene de dados;
- Remoção de valores nulos e colunas descartáveis.

```
# vírgula decimal -> ponto
dados['km'] = pd.to_numeric(dados['km'].astype(str).str.replace(',', '.'))
dados['latitude'] = pd.to_numeric(dados['latitude'].astype(str).str.replace(',', '.'))
dados['longitude'] = pd.to_numeric(dados['longitude'].astype(str).str.replace(',', '.'))

# br é o nome da rodovia, não quantidade. 0 não existe como rodovia.
dados['br'] = dados['br'].astype(str)
dados['br'] = dados['br'].replace('0', 'Desconhecido')

dados['condicao_metereologica'] = dados['condicao_metereologica'].replace('Ignorado', 'Desconhecido')
dados['sentido_via'] = dados['sentido_via'].replace('Não Informado', 'Desconhecido')
```

```
colunas_fora = [
    # vazamento: desfecho do acidente
    'classificacao_acidente', 'mortos', 'feridos_graves', 'feridos_leves',
    'feridos', 'ilesos', 'ignorados',
    # não descrevem o acidente
    'id', 'municipio', 'latitude', 'longitude',
    'regional', 'delegacia', 'uop', 'uf',
]
```

Regra	Linhas afetadas
Vírgula decimal virou ponto (km, latitude, longitude)	39.849
br = 0 virou Desconhecido	44
Ignorado no clima virou Desconhecido	341
Não Informado no sentido virou Desconhecido	44
Duplicatas removidas	0


Divisão entre treino e teste

- Divisão temporal: **treino** de **2021 a 2024** (31.663 registros) e **teste** em **2025** (8.186).
- O modelo aprende com o passado e é avaliado em um ano que nunca viu.

2021	2022	2023	2024	2025
TREINO				TESTE

Ano	% de fatais
2021	3,81%
2022	4,16%
2023	4,10%
2024	4,33%
2025	4,57%

Análise exploratória: tipo de acidente



Análise exploratória: outras variáveis

% de fatais	Categoria A	Categoria B
Uso do solo	Rural: 5,42%	Urbano: 2,79%
Tipo de pista	Simplex: 5,15%	Dupla: 2,49%
Fase do dia	Plena noite: 5,83%	Pleno dia: 2,92%

- Às 23h a taxa é de 8,47%; às 8h, 2,39%.
- Acidentes com mais de 1,5 pessoa por veículo: 6,00%, contra 3,30% nos demais.
- Categorias com poucos casos enganam: "Vento" tem 25%, mas são só 8 ocorrências.

Análise exploratória: método

```
for col in ['tipo_acidente', 'uso_solo', 'tipo_pista', 'fase_dia',
           'condicao_metereologica', 'sentido_via', 'dia_semana']:
    t = treino.groupby(col)['grave'].agg(['count', 'mean'])
    t['pct_grave'] = (t['mean'] * 100).round(2)
    print(f"--- {col} ---")
    print(t[['count', 'pct_grave']].sort_values('pct_grave', ascending=False))
    print()

# quantas categorias tem cada uma
for col in ['causa_acidente', 'tracado_via', 'tipo_acidente', 'br']:
    print(f"{col}: {treino[col].nunique()} categorias")
```

```
--- tipo_acidente ---
count  pct_grave
tipo_acidente
Atropelamento de Pedestre    924    26.30
Colisão frontal              2108    19.54
Eventos atípicos              79     6.33
Colisão lateral sentido oposto 782     4.86
Atropelamento de Animal      165     3.03
Colisão com objeto            2637     3.00
Saída de leito carroçável     4208     2.97
Tombamento                   2600     2.69
Colisão traseira              6478     2.19
Derramamento de carga        53     1.89
Colisão transversal           5006     1.82
Colisão lateral               111     1.80
Engavetamento                517     1.55
Colisão lateral mesmo sentido  4011     1.45
Queda de ocupante de veículo  1014     1.28
Capotamento                  593     1.18
Incêndio                      377     0.27
```

```
--- uso_solo ---
count  pct_grave
uso_solo
Não    15817    5.42
Sim    15846    2.79
```

```
--- tipo_pista ---
count  pct_grave
tipo_pista
Simples 14930    5.15
Múltipla 6119    4.36
Dupla   10614    2.49
```

```
--- fase_dia ---
count  pct_grave
fase_dia
Plena Noite 11238    5.83
Amanhecer   1332    5.63
Anoitecer    1625    3.69
Pleno dia    17468    2.92
```

```
--- condicao_metereologica ---
count  pct_grave
condicao_metereologica
Vento      8    25.00
Nevoeiro/Neblina 392    7.91
Nublado    7269    4.48
Garoa/Chuvisco 1895    4.43
Chuva      3986    4.42
Céu Claro  16026    3.84
Sol         1829    3.34
Desconhecido 257    1.95
Neve        1     0.00
```

```
--- sentido_via ---
count  pct_grave
sentido_via
Decrescente 15055    4.22
Crescente   16574    4.01
Desconhecido 34     0.00
```

```
--- dia_semana ---
count  pct_grave
dia_semana
sábado    5453    4.77
domingo    4993    4.39
quarta-feira 3906    4.35
segunda-feira 4238    4.01
quinta-feira 4107    3.92
sexta-feira 5082    3.60
terça-feira 3884    3.53
```

```
causa_acidente: 74 categorias
tracado_via: 439 categorias
tipo_acidente: 17 categorias
br: 12 categorias
```

Pré-processamento

Ausentes	"Ignorado" e "Não Informado" viraram a categoria "Desconhecido"; sem imputação.
Categóricas	One-Hot Encoding, resultando em 89 colunas.
Escala	RobustScaler, porque os valores extremos (ônibus, engavetamentos) têm muitos casos fatais e foram mantidos.
Atributos novos	Hora, mês e ocupação (pessoas ÷ veículos).

Tudo dentro de um pipeline, ajustado só no treino, para evitar vazamento de dados.

Desbalanceamento e métricas

Um classificador que responde sempre "não grave" acerta 95,9% e tem revocação zero.

- **Métrica principal:** revocação da classe grave. F1 e ROC-AUC apoiam; a precisão serve de controle.
- 
- **Regressão Logística:** *class_weight balanced* (errar um fatal custa cerca de 23 vezes mais).
 - **KNN:** testamos subamostragem e SMOTE.

Estado da arte: comparação

Trabalho	Dados	Desbalanceamento	Divisão
Mafort e Kappel	PRF, RJ	Subamostragem	Aleatória
Gabardo et al.	PRF, Sul, por pessoa	SMOTE	Aleatória
Sousa et al.	Teresina	SMOTE	Aleatória
Fiorentini e Losa	Rodoviário	Subamostragem	Aleatória
Malaquias et al.	PRF, Brasil	Subamostragem	Aleatória
Este trabalho	PRF, SC, por ocorrência	Peso, subamostragem, SMOTE	Temporal

Os outros trabalhos sorteiam treino e teste; aqui o teste é o ano de 2025 inteiro.
Os coeficientes da Regressão Logística explicam o modelo, sem LIME ou SHAP.

Modelos e otimização

GridSearchCV com validação cruzada de 5 divisões, usando o F1 da classe grave como critério.

Modelo A

Regressão Logística

- C testado em 0,01; 0,1; 1 e 10;
- Escolhido 0,1.
- *class_weight balanced*.

Modelo B

KNN

- N° de vizinhos e ponderação testados no grid;
- Treino com subamostragem.

Com SMOTE, o KNN decorou o treino: F1 de 0,436 no treino e 0,245 no teste.
Por isso o Modelo B usa subamostragem.

Resultados no conjunto de teste

Modelo	Acurácia	Revocação	Precisão	F1	ROC-AUC
Logística, peso de classe (A)	0,804	0,722	0,152	0,252	0,853
Logística com subamostragem	0,804	0,727	0,153	0,253	0,845
Logística SMOTE	0,820	0,703	0,162	0,263	0,854
KNN, subamostragem (B)	0,816	0,650	0,150	0,244	0,810
KNN SMOTE	0,868	0,471	0,166	0,245	0,750
KNN, sem balanceamento	0,952	0,070	0,356	0,116	0,657

Logística: achou 270 dos 374 fatais, perdeu 104 e deu 1.503 alarmes falsos. **KNN (B):** achou 243, perdeu 131 e deu 1.373 alarmes falsos.

KNN sem balanceamento: tem a maior acurácia (0,952) e a pior revocação.

Logística: F1 de 0,258 no treino e 0,252 no teste, sem sobreajuste.

Matriz de confusão

Regressão Logística


Real	Não grave	6309	1503
	Grave	104	270
		Não grave	Grave
		Previsto	

KNN com subamostragem


Real	Não grave	6439	1373
	Grave	131	243
		Não grave	Grave
		Previsto	

O FN é o erro que mais pesa: a Logística deixa passar 104 fatais, contra 131 do KNN.

Curva ROC





Coeficientes da Regressão Logística



- Coeficiente indica associação com as outras variáveis mantidas iguais, não causa.
- Confirma os valores levantados durante EDA.

Produto final

- **Notebook no Google Colab e repositório:**
github.com/joao1824/projeto-ml-prf
- **Aplicação web com mapa de SC:**
cada acidente é colorido pela combinação entre gravidade real e previsão do modelo.



Conclusão

Criação de modelo de classificação binária para estimar se um acidente em rodovia federal de SC teve vítima fatal:

Modelo	Acurácia	Revocação	Precisão	F1	ROC-AUC
Regressão logística	0,804	0,722	0,152	0,252	0,853

Que apesar das qualidades, ainda possui certas limitações:

- A precisão do modelo é de 0,152, ou seja, cerca de 15% dos acidentes que ele sinaliza como graves realmente tiveram vítima fatal.
- O escopo se limita a rodovias federais (BRs) de Santa Catarina.

Referências

- FIORENTINI, Nicholas; LOSA, Massimo. **Handling imbalanced data in road crash severity prediction by machine learning algorithms.** Infrastructures, v. 5, n. 7, p. 61, 2020.
- GABARDO, Arthur M. P. et al. **Highway to... determining fatal outcomes in traffic accidents based on police reports.** In: BRAZILIAN CONFERENCE ON INTELLIGENT SYSTEMS (BRACIS), 35., 2025, Fortaleza. Anais. Porto Alegre: Sociedade Brasileira de Computação, 2025. p. 230-244.
- MAFORT, Evandro V.; KAPPEL, Marco A. A. **Técnicas de aprendizado de máquina para predição de gravidade de acidentes em rodovias do estado do Rio de Janeiro.** Revista Eletrônica de Iniciação Científica em Computação, v. 23, n. 1, p. 244-252, 2025.
- MALAQUIAS, Eveline Oliveira; TOSTA, Marielce de Cássia Ribeiro; CHAVES, Gisele de Lorena Diniz; RIBEIRO, Glaydston Mattos. **Acidentes em rodovias brasileiras: um estudo com técnicas de Machine Learning para classificar a causa das ocorrências.** In: CONGRESSO DE PESQUISA E ENSINO EM TRANSPORTES (ANPET), 35., 2021. Anais. 2021.
- MATTOS, Victor G. P. de; VASCONCELOS, Pedro H. V. de; PARCIANELLO, Yussef; KOZIEVITCH, Nádia P.; BERARDI, Rita. **Visualização dos dados abertos da Polícia Rodoviária Federal sobre acidentes nas rodovias brasileiras.** In: SIMPÓSIO BRASILEIRO DE BANCO DE DADOS (SBBBD), 34., 2019. Anais. 2019. p. 193-198.
- SOUSA, George Isaac Lopes de; RODRIGUES, Maria Clara de Oliveira; ROSA, Amanda Gadelha Ferreira. **Aprendizado de máquina na análise de sinistros de trânsito: um estudo na zona urbana de Teresina - PI.** Scientia Generalis, v. 7, n. 1, p. 1157-1175, 2026.

Obrigado pela atenção!

Alguma dúvida?

Bruno Pagani Rampinelli
João Henrique Camilo Fogaça
Vinícius dos Santos Nascimento

Projeto Machine Learning
Engenharia de Computação | UNISATC

